ML-এর প্রথম ধাপ: ডেটা বোঝা (EDA)

Titanic ডেটাসেটে প্লট ও তার ব্যবহার

পাঁচটি প্লট, পাঁচটি সহজ উদাহরণ

Titanic ডেটাসেট: ডেটাটা কেমন?

১৯১২ সালের এপ্রিলে বিশাল জাহাজ টাইটানিক প্রথম সমুদ্রযাত্রায় হিমশৈলে ধাক্কা খেয়ে ডুবে যায়। ডেটাসেটে প্রতিটি সারি একজন যাত্রীর পরিচয়পত্রের মতো: তিনি কে, কত বয়সের, কোন শ্রেণিতে ভ্রমণ করছিলেন, আর শেষ পর্যন্ত বেঁচেছিলেন কি না।

৮৯১
যাত্রী (সারি)

১২
তথ্যের ঘর (কলাম)

~৩৮%
বেঁচেছেন

ML-এর কাজ কী?

যাত্রীর তথ্য দেখে আন্দাজ করা, তিনি বেঁচেছেন কি না। এই আন্দাজ শেখানোর আগে ডেটাকে চেনাই আমাদের প্রথম কাজ।

যে কলামগুলো আমরা ব্যবহার করব

Survived	বেঁচেছেন কি না (০ = না, ১ = হ্যাঁ)
Sex	নারী নাকি পুরুষ
Age	যাত্রীর বয়স
Fare	টিকিটের দাম

আরও আছে: Pclass (টিকিটের শ্রেণি), Name, SibSp, Parch, Ticket, Cabin, Embarked

প্লট ১ / ৫

লাইন প্লট

১. Titanic-এর প্রশ্ন

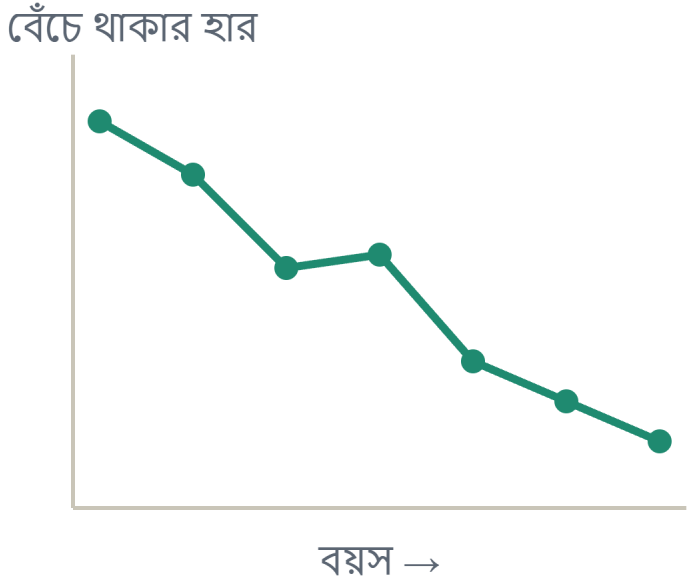
বয়স বাড়ার সাথে সাথে কি বেঁচে ফেরার সুযোগ বদলে যায়? শিশু আর বয়স্কদের ভাগ্য কি একই ছিল?

২. ছবি আমাদের কী বলে

বয়সকে ধাপে ধাপে ভাগ করা হয় (০–১০, ১১–২০...)। প্রতি ধাপে কত শতাংশ বেঁচেছেন তা হিসাব করে বিন্দু বসিয়ে লাইন টানা হয়। দেখা যায়, ছোটদের বেঁচে থাকার হার তুলনামূলক বেশি ছিল, কারণ উদ্ধারের সময় নারী ও শিশুদের আগে নেওয়ার চেষ্টা হয়েছিল।

৩. ML-এ কীভাবে কাজে লাগে

লাইনটা দেখেই বোঝা যায়, Age কলামটা মডেলের জন্য দামি সূত্র। ঠিক গোয়েন্দার মতো: কোন সূত্র কাজের তা আগে চিনে নিই, তারপর মডেলকে শেখাই।



বিশ্লেষণের কলাম

Age ও Survived

প্লট ২ / ৫

স্ক্যাটার প্লট

১. Titanic-এর প্রশ্ন

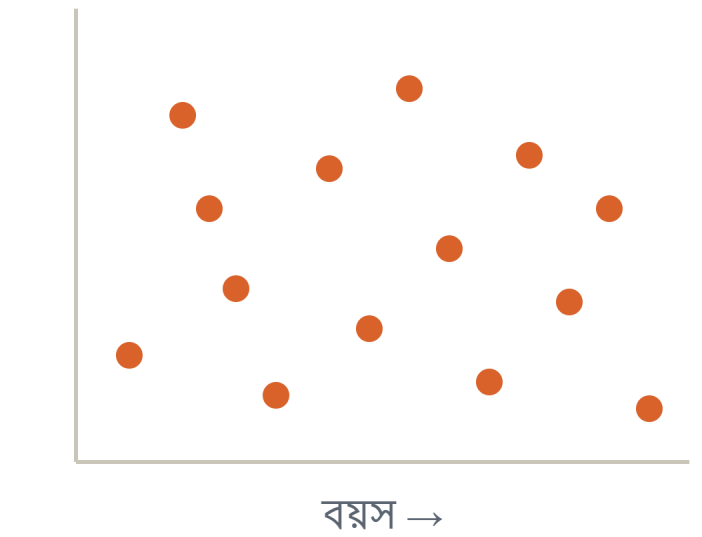
যাঁদের বয়স বেশি, তাঁরা কি বেশি দামের টিকিট কিনেছিলেন? নাকি দুটোর মধ্যে কোনো মিলই নেই?

২. ছবি আমাদের কী বলে

প্রতিটি বিন্দু একজন যাত্রী। আড়াআড়ি দিকে তাঁর বয়স, উপর-নিচে টিকিটের দাম। বিন্দুগুলো এলোমেলো ছড়িয়ে থাকলে বুঝব, দুটোর মধ্যে তেমন সম্পর্ক নেই। একটা ধারা ফুটে উঠলে সম্পর্ক আছে।

৩. ML-এ কীভাবে কাজে লাগে

যদি দুটি কলাম প্রায় একই কথা বলে, মডেলকে দুটোই দেওয়ার দরকার নেই। আবার যে কলাম উত্তরের সাথে জড়িত, তাকেও চেনা যায়। এভাবে কাজের কলাম বেছে নেওয়া সহজ হয়।



বিশ্লেষণের কলাম

Age ও Fare

প্লট ৩ / ৫

হিস্টোগ্রাম

১. Titanic-এর প্রশ্ন

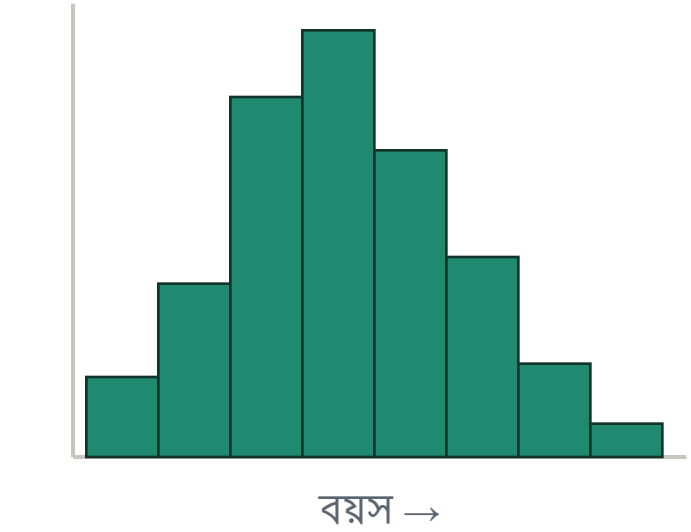
জাহাজে কোন বয়সের মানুষ সবচেয়ে বেশি ছিলেন? কিশোর, তরুণ, নাকি বৃদ্ধ?

২. ছবি আমাদের কী বলে

বয়সকে কয়েকটা ঘরে ভাগ করে প্রতিটি ঘরে কতজন আছেন তা গুনে স্তম্ভ আঁকা হয়। যে স্তম্ভ সবচেয়ে উঁচু, সেই বয়সের যাত্রী সবচেয়ে বেশি। কিছু যাত্রীর বয়স লেখাই নেই, তাই গোনার সময় তাঁদের আলাদা করে নিতে হয়।

৩. ML-এ কীভাবে কাজে লাগে

মডেল ভালো খাবারের মতো ভালো ডেটা চায়। হিস্টোগ্রামে অদ্ভুত বা একদম আলাদা মান চোখে পড়লে আগে তা ঠিক করে নিই, তারপর মডেল বানাই।



বিশ্লেষণের কলাম

Age

প্লট ৪ / ৫

বার চার্ট

১. Titanic-এর প্রশ্ন

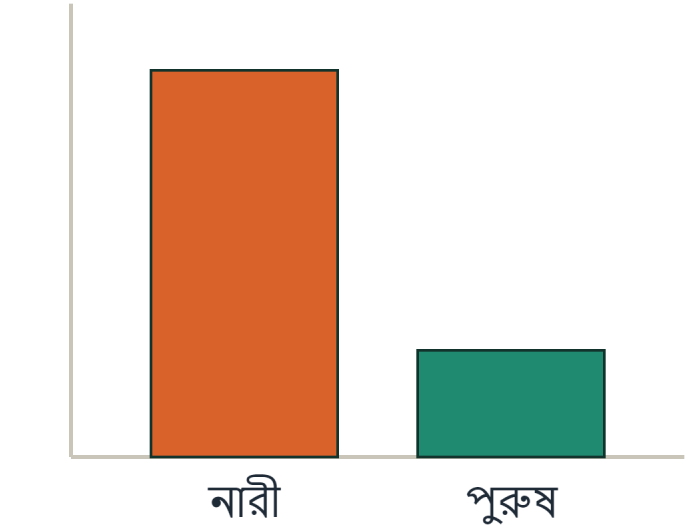
নারী ও পুরুষের মধ্যে কোন দলের কতজন করে বেঁচেছেন?

২. ছবি আমাদের কী বলে

প্রতিটি দলের জন্য একটা করে স্তম্ভ: একটা নারীদের, আরেকটা পুরুষদের। স্তম্ভ যত উঁচু, বেঁচে ফেরা মানুষ তত বেশি। দুটো পাশাপাশি রাখলে এক নজরেই তুলনা হয়ে যায়। ছবিটি নমুনা।

৩. ML-এ কীভাবে কাজে লাগে

Sex কলামটা উত্তরের ওপর বড় প্রভাব ফেলে, তাই মডেলের জন্য এটি শক্তিশালী সূত্র। কোনো দলের তথ্য খুব কম থাকলে মডেল সেই দল নিয়ে ভুল শিখতে পারে, সেটাও আগে ধরা পড়ে।



বিশ্লেষণের কলাম

Sex ও Survived

প্লট ৫ / ৫

পাই চার্ট

১. Titanic-এর প্রশ্ন

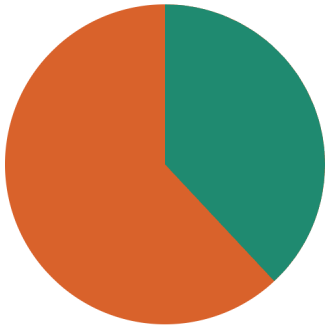
জাহাজের মোট যাত্রীর কত অংশ শেষ পর্যন্ত বেঁচেছিলেন?

২. ছবি আমাদের কী বলে

একটা গোল Pizza ভাগ করার মতো ভাবুন: বেঁচেছেন আর বাঁচেননি, দুই টুকরোর আকার দেখলেই বোঝা যায় কোনটা বড়। এখানে বেঁচেছেন প্রায় ৩৮% আর বাঁচেননি প্রায় ৬২%।

৩. ML-এ কীভাবে কাজে লাগে

Survived হলো সেই উত্তর, যা মডেল আন্দাজ করতে শিখবে। দুই পক্ষ খুব অসমান হলে মডেল সহজ পথ ধরে শুধু বড় পক্ষটাই বলে দেয়। তাই আগেই অনুপাত দেখে নিই।



বেঁচেছে: প্রায় ৩৮%

বাঁচেনি: প্রায় ৬২%

বিশ্লেষণের কলাম

Survived

সারকথা

লাইন প্লট	বয়সের সাথে বেঁচে থাকার হার কেমন বদলায়	কলাম: Age, Survived
স্ক্যাটার প্লট	দুটি তথ্যের মধ্যে সম্পর্ক আছে কি না	কলাম: Age, Fare
হিস্টোগ্রাম	মান কোথায় জমে আছে, অদ্ভুত মান আছে কি না	কলাম: Age
বার চার্ট	গ্রুপ ধরে সংখ্যার তুলনা	কলাম: Sex, Survived
পাই চার্ট	পুরোটার মধ্যে কোন অংশ কত শতাংশ	কলাম: Survived

আগে ডেটাকে চিনুন, তারপর মডেল বানান।